

Gate 实验 — 最终结论：通过

一句话：Rollout 中途第 K=10-15 步的动作 divergence 能预测最终 reward variance，Spearman ρ 最高 0.42 ($p=1.4\times10^{-5}$)，AUROC 最高 0.77。信号足够强，值得把 per-group early termination 做进正式 project。

实验配置

- 环境：ALFWorld (TextWorld 后端)，混合 6 种任务类型。
- 模型：Qwen2.5-7B-Instruct，单 VLLM engine，temperature 0.7。
- 任务数：valid_seen 切分里随机抽 100 个 (seed=42)。
- 组大小 G：每个任务并行采 8 条 trajectory (同一初始状态，独立采样)。
- Max steps：30。
- 耗时：单张 RTX 6000 Ada 上 45 分钟跑完，零失败。

100 个 group 的结果分布：

- 全败 (reward 0/8)：25 组
- 混合 (非零方差)：61 组
- 全胜 (reward 8/8)：14 组
- 零方差比例：39% (25+14)

如果能在 step=10 完美识别出零方差组，理论可节省的 rollout 算力 $\approx 39/100 \times (30-10)/30 \approx 26\%$ 。

核心数字

排名	K	divergence 指标	Spearman ρ	p-value	AUROC (div → 非零方差)
1	15	prefix_edit_distance_mean	0.419	1.4×10^{-5}	0.773
2	20	prefix_edit_distance_mean	0.418	1.5×10^{-5}	0.753
3	10	action_bigram_jaccard_mean	0.407	2.7×10^{-5}	0.770
4	15	action_bigram_jaccard_mean	0.406	2.8×10^{-5}	0.752
5	10	unique_prefix_ratio	0.398	4.0×10^{-5}	0.751

Gate 标准 ($|p| \geq 0.4$ 或 $2\times(\text{AUROC}-0.5) \geq 0.4$)：28 个 (metric × K) 组合中有 5 个通过。

信号在哪里：K=10-15 是 sweet spot

ρ / AUROC 双指标网格 (详见 figures/heatmap_rho_auroc.png)：

指标 \ K	5	10	15	20
unique_action_ratio	0.31 / 0.70	0.38 / 0.75	0.27 / 0.64	0.17 / 0.58
unique_prefix_ratio	0.32 / 0.70	0.40 / 0.75	0.31 / 0.67	0.21 / 0.61
action_bigram_jaccard_mean	0.29 / 0.69	0.41 / 0.77	0.41 / 0.75	0.39 / 0.72
prefix_edit_distance_mean	0.25 / 0.66	0.37 / 0.76	0.42 / 0.77	0.42 / 0.75
obs_unique_ratio	0.25 / 0.66	0.40 / 0.75	0.31 / 0.66	0.09 / 0.53
action_entropy	0.29 / 0.70	0.37 / 0.74	0.26 / 0.64	0.16 / 0.57
termination_fraction	-0.19 / 0.45	-0.06 / 0.51	0.11 / 0.56	0.16 / 0.59

(格式 : ρ / AUROC)

- K=5 太早：大部分 trajectory 还在跑开头那几个固定动作（go to cabinet 1 之类），还没拉开差距。
- K=10-15 最优：8 条 trajectory 已经显露出各自的"意图"，同时距离终点还远，gate 的边际收益最大。
- K=20 信号仍存，但代价也上来了（距离 30 步的 max 已经跑了 2/3）。
- termination_fraction 单独用没用：全胜组早早结束、全败组根本不结束，两类零方差在这维度上往相反方向拉。

发现了一个不对称性

按 group 最终结果分三类做的 stratified scatter (figures/stratified_prefix_edit_distance_mean_K15.png)：

- 全胜组 (n=14)：紧紧聚集在低 divergence (基本 ≤ 0.3)。模型知道怎么做时，8 条采样收敛一致——容易识别。
- 混合组 (n=61)：分散在中到高 divergence (0.1-0.85)，中心约 0.5。和全胜组分离明显。
- 全败组 (n=25)：分散在整个范围 (0.0-0.75)。模型有时锁步地犯同样的错（低 div），有时混乱地各自瞎撞（高 div，但还是没人赢）。

对 per-group early termination 的含义：

- 容易砍的零方差组 #1：正在收敛到成功（低 div $\rightarrow$ 8 条采样基本一致，稳）。
- 容易砍的零方差组 #2：协调地在犯错（低 div，8 条都在同一个错误路径上）。
- 最难识别：高 div 的全败组——它们看起来就像非零方差的混合组。这类只能用 DAPO 那种事后 filter，early termination 救不了。

建议正式版用双阈值 gate："div@15 < 0.10 或 div@15 > 0.75 $\rightarrow$ 提前终止"，两端通吃。

按任务类型看

每个任务类型内部的最佳信号 (correlation_by_task_type.csv)：

task_type	n	最佳 K	最佳 metric	ρ	AUROC
look_at_obj_in_light	8	15	unique_prefix_ratio	0.810	1.000
pick_two_obj_and_place	20	20	termination_fraction	0.788	0.857
pick_cool_then_place_in_recep	19	20	termination_fraction	0.730	0.821
pick_and_place_simple	24	15	unique_action_ratio	0.688	0.857
pick_heat_then_place_in_recep	11	10	action_entropy	0.546	1.000
pick_clean_then_place_in_recep	18	15	termination_fraction	0.457	0.708

6 个任务类型上信号都稳（最低 AUROC 0.71，中位数 0.86）。但每类最佳指标不同 —— 说明 task-aware gate（针对任务类型选 K 和 metric）会比单一全局阈值更强。

具体例子

典型"该砍"的零方差组（低 **div** + 全胜）

任务：`pick\_and\_place\_simple` —— 8/8 成功，div@10 = 0.000

```
traj 0: go to cabinet 1 | open cabinet 1 | go to cabinet 2 | open cabinet 2 | ...
traj 1: go to cabinet 1 | open cabinet 1 | go to cabinet 2 | open cabinet 2 | ...
... （8 条前 10 步完全相同，最后全胜）
```

→ 到 step 10 就已经能判定这组对梯度贡献为零。提前砍。

典型"该留"的非零方差组（高 **div** + 混合）

任务：`look\_at\_obj\_in\_light` —— 5/8 成功，div@10 = 0.748

```
traj 0: go to bed 1 | go to desk 1 | go to sidetable 1 | go to sidetable 2 | use desk lamp 1 | look
traj 3: go to bed 1 | take pillow 1 from bed 1 | go to desk 1 | look | go to sidetable 1 | ...
traj 7: go to bed 1 | take pillow 1 from bed 1 | go to desk 1 | go to sidetable 1 | go to sidetable 2 | use ...
```

→ 8 条 trajectory 分化成不同的探索策略 → 最终有胜有败 → 8 条全留。

Gate 失败的边缘 case

任务：`pick\_and\_place\_simple` —— 3/8 成功，div@10 = 0.000

（8 条前 10 步完全相同，到 step 10 之后才分化成不同的终局动作）

→ 如果在 K=10 判定，会误判为零方差提前砍掉。修法：用 K=15 或 20；或者按任务类型 task-aware 地选 K。

结论

可以做正式 project。信号统计显著（ $p < 10^{-4}$ ），方向与假设一致，绝对值也足够强（ $|\rho| \approx 0.42$ ，AUROC ≈ 0.77 ）。建议把 per-group early-termination 做进 GRPO 的 rollout 循环。前面发现的

不对称性说明，生产版的 gate 应当是双阈值 —— 低 div 和高 div 两端都砍。


下一步（超出本 **gate** 实验的范围）

- WebShop 上验证泛化性（agent-native 的信号应当能迁移；math 没有这种结构）。
 - $G=16$ 看 divergence 度量会不会更稳定。
 - 真正把 early-termination 接进 verl/GRPO 的 rollout 闭环，量化：节省多少算力 vs 梯度范数下降多少。
 - Task-aware K 选择：根据任务类型挑选最优 (metric, K) 组合。
-


产物清单

- `data/rollouts.jsonl` — 100 组 $\times$ 8 轨迹的原始 rollout 数据（可复现）
- `data/metrics.parquet` — 每组的 divergence metrics $\times$ K
- `results/correlation\_table.csv` — Spearman ρ + AUROC 表
- `results/correlation\_by\_task\_type.csv` — 按任务类型拆分的相关性
- `results/figures/heatmap\_rho\_auroc.png` — (metric $\times$ K) 双指标热力图
- `results/figures/stratified\_prefix\_edit\_distance\_mean\_K15.png` — 三分层散点
- `results/figures/hist\_zero\_vs\_nonzero.png` — 零方差 vs 非零方差的 div 分布对比
- `results/figures/scatter\_K{5,10,15,20}.png` — 各 K 下所有 metric 的散点矩阵
- `results/report.md` / `results/report\_zh.md` — 英文 / 中文报告

附录：关键图




ρ / AUROC 双指标热力图 (所有 $metric \times K$ 组合)




三分层散点 ($prefix_edit_distance_mean @ K=15$)

Divergence distribution: zero-var vs non-zero-var groups




零方差 vs 非零方差：各 $metric \times K$ 的分布对比

Divergence at step K=10 vs final reward variance



scatter @ K=10

Divergence at step K=15 vs final reward variance



scatter @ K=15